Рубежный контроль №2. Тема: Методы построения моделей машинного обучения.

Выполнил:

студент группы РТ5-61Б Незаметдинов Тимур

В качестве датасета набор данных домов для аренды в разных городах Бразилии. Стоит задача предсказать финальную стоимость аренды, т.е. решается задача регрессии.

Импорт библиотек

Импортируем необходимые для выполнения работы библиотеки

In [1]:
```
import pandas as pd
import numpy as np
from matplotlib import pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeRegressor
from xgboost import XGBRegressor
from sklearn.model_selection import RepeatedKFold
from sklearn.model_selection import cross_val_score
from sklearn.metrics import mean_absolute_error, mean_squared_error, median_absolute_error, r2_score
from sklearn.model_selection import GridSearchCV, RandomizedSearchCV
pd.options.display.float_format = '{:.0f}'.format
```

Загрузка данных

Прочитаем имеющийся набора данных в переменную

In [2]:
```
data = pd.read_csv('houses_to_rent_v2.csv')
```

Выведем основую информацию и статистические показатели по датасету

In [3]:
```
data.head()
```

Out[3]:

	city	area	rooms	bathroom	parking spaces	floor	animal	furniture	hoa (R$)	rent amount (R$)	property tax (R$)	fire insurance (R$)	total (R$)
0	São Paulo	70	2	1	1	7	acept	furnished	2065	3300	211	42	5618
1	São Paulo	320	4	4	0	20	acept	not furnished	1200	4960	1750	63	7973
2	Porto Alegre	80	1	1	1	6	acept	not furnished	1000	2800	0	41	3841
3	Porto Alegre	51	2	1	0	2	acept	not furnished	270	1112	22	17	1421
4	São Paulo	25	1	1	0	1	not acept	not furnished	0	800	25	11	836

In [4]:
```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10692 entries, 0 to 10691
Data columns (total 13 columns):
 #   Column               Non-Null Count  Dtype
---  ------               --------------  -----
 0   city                 10692 non-null  object
 1   area                 10692 non-null  int64
 2   rooms                10692 non-null  int64
 3   bathroom             10692 non-null  int64
 4   parking spaces       10692 non-null  int64
 5   floor                10692 non-null  object
 6   animal               10692 non-null  object
 7   furniture            10692 non-null  object
 8   hoa (R$)             10692 non-null  int64
 9   rent amount (R$)     10692 non-null  int64
 10  property tax (R$)    10692 non-null  int64
 11  fire insurance (R$)  10692 non-null  int64
 12  total (R$)           10692 non-null  int64
dtypes: int64(9), object(4)
memory usage: 1.1+ MB
```

In [5]:
```
data.describe()
```

Out[5]:

	area	rooms	bathroom	parking spaces	hoa (R$)	rent amount (R$)	property tax (R$)	fire insurance (R$)	total (R$)
count	10692	10692	10692	10692	10692	10692	10692	10692	10692
mean	149	3	2	2	1174	3896	367	53	5490
std	537	1	1	2	15592	3409	3108	48	16485
min	11	1	1	0	0	450	0	3	499
25%	56	2	1	0	170	1530	38	21	2062
50%	90	2	2	1	560	2661	125	36	3582
75%	182	3	3	2	1238	5000	375	68	6768
max	46335	13	10	12	1117000	45000	313700	677	1120000

In [6]:
```
sns.heatmap(data.corr(), annot=True, fmt='.1f')
```

Out[6]: <AxesSubplot:>

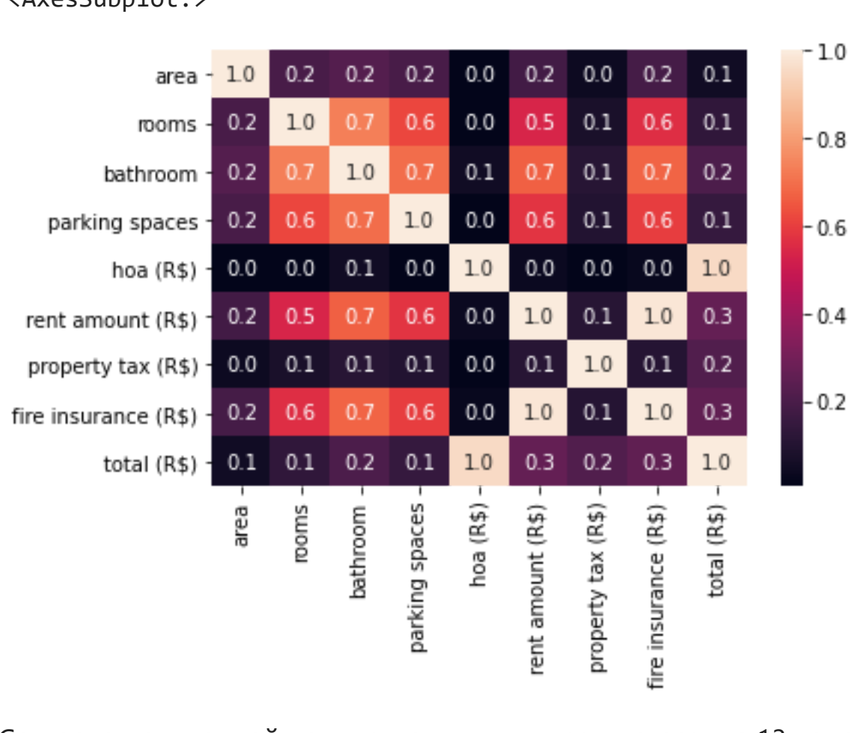

Согласно полученной документации мы имеем датасет из 13 колонок и 10692 строк:

Признаки

- `city` - город, в котором расположена квартира
- `area` - площадь квартиры
- `rooms` - количество комнат в квартире
- `bathroom` - количество ванных комнат
- `parking spaces` - количество парковочных мест
- `floor` - этаж, на котором расположена квартира
- `animal` - разрешение на проживание с домашним животным
- `furniture` - мебель
- `hoa` - налог на товарищество собственников жилья
- `rent amount` - размер арендной платы
- `property tax` - налог на имущество
- `fire insurance` - страховка от пожара

Целевая переменная

- `total` - суммарная стоимость аренды

В данных остутствуют явные пропуски, однако о качестве данных все же известно мало, поэтому потребуется предобработка.

Предобработка данных

Переименование столбцов

In [7]:
```
data.columns
```

Out[7]:
```
Index(['city', 'area', 'rooms', 'bathroom', 'parking spaces', 'floor',
       'animal', 'furniture', 'hoa (R$)', 'rent amount (R$)',
       'property tax (R$)', 'fire insurance (R$)', 'total (R$)'],
      dtype='object')
```

In [8]:
```
data = data.rename(columns={'hoa (R$)':'hoa',
                            'rent amount (R$)':'rent_amount',
                            'property tax (R$)':'property_tax',
                            'fire insurance (R$)' : 'fire_insurance',
                            'total (R$)' : 'total',
                            'parking spaces' : 'parking_spaces'})
```

Обработка пропусков

В блоке информации по всему датасету можно заметить, что параметр floor имеет тип данных **object**, а по своему смыслу хранит целочисленные значения, видимо внутри есть пропуски, заполненные "заглушками", которые не позволяют определить верный тип хранимых данных.

In [9]:
```
data['floor'].value_counts()
```

Out[9]:
```
-      2461
1      1081
2       985
3       931
4       748
5       600
6       539
7       497
8       490
9       369
10      357
11      303
12      257
13      200
14      170
15      147
16      109
17       96
18       75
19       53
20       44
21       42
25       25
23       25
22       24
26       20
24       19
27        8
28        6
29        5
32        2
301       1
51        1
46        1
35        1
Name: floor, dtype: int64
```

Так и есть, значений, заполненных "заглушкой" в виде - почти 25% датасета. Видимо при сборе данных некоторые пользователи не указали этаж и на этом месте появилась заглушка, или же опрос проводили несколько раз, и поле с номером этажа было не всегда.

In [10]:
```
data['floor'].value_counts().plot(kind='bar')
```

Out[10]: <AxesSubplot:>

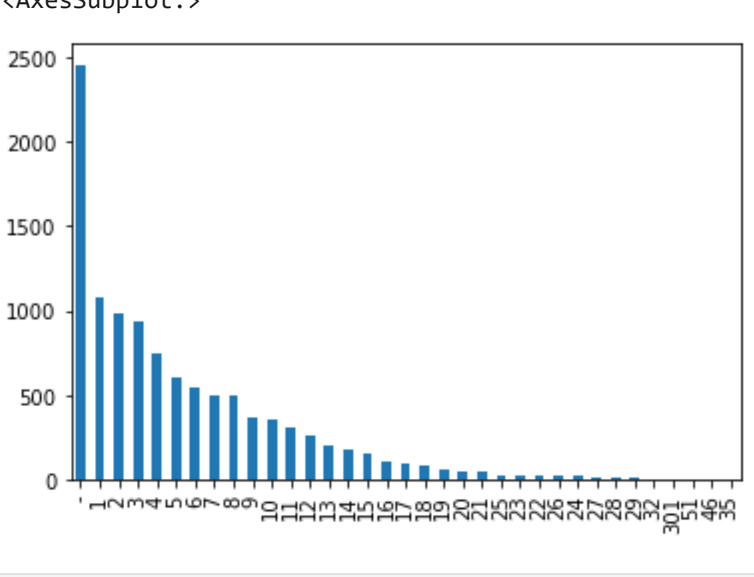

In [11]:
```
data.query('floor != "-"')['floor'].value_counts().plot(kind='bar')
```

Out[11]: <AxesSubplot:>

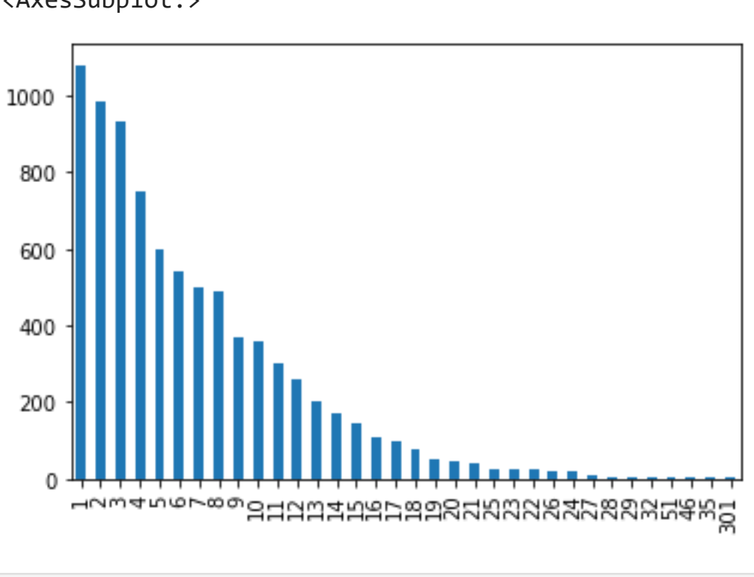

In [12]:
```
data.query('floor != "-"')['floor'].median()
```

Out[12]: 5.0

Заполнять медианным и средним нельзя, это сильно исказит исходное распределение, поэтому уберем эти записи из нашего датасета, чтобы не повредить качество обработанных данных.

In [13]:
```
data = data.query('floor != "-"').reset_index(drop=True)
data = data.astype({'floor':'int32'})
```

In [14]:
```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8231 entries, 0 to 8230
Data columns (total 13 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   city            8231 non-null   object
 1   area            8231 non-null   int64
 2   rooms           8231 non-null   int64
 3   bathroom        8231 non-null   int64
 4   parking_spaces  8231 non-null   int64
 5   floor           8231 non-null   int32
 6   animal          8231 non-null   object
 7   furniture       8231 non-null   object
 8   hoa             8231 non-null   int64
 9   rent_amount     8231 non-null   int64
 10  property_tax    8231 non-null   int64
 11  fire_insurance  8231 non-null   int64
 12  total           8231 non-null   int64
dtypes: int32(1), int64(9), object(3)
memory usage: 803.9+ KB
```

Кодирование категориальных признаков

Закодируем категориальные признаки с помощью техники One-Hot Encoding

In [15]:
```
data_ohe = pd.get_dummies(data, columns=['city', 'animal', 'furniture'], drop_first=1)
```

In [16]:
```
data_ohe
```

Out[16]:

	area	rooms	bathroom	parking_spaces	floor	hoa	rent_amount	property_tax	fire_insurance	total	city_Campinas	city_Porto Alegre	city_Rio de Janeiro	city_São Paulo	animal_not acept	furniture_not furnished
0	70	2	1	1	7	2065	3300	211	42	5618	0	0	0	1	0	0
1	320	4	4	0	20	1200	4960	1750	63	7973	0	0	0	1	0	1
2	80	1	1	1	6	1000	2800	0	41	3841	0	1	0	0	0	1
3	51	2	1	0	2	270	1112	22	17	1421	0	1	0	0	0	1
4	25	1	1	0	1	0	800	25	11	836	0	0	0	1	1	1
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
8226	150	3	3	2	8	0	13500	0	172	13670	0	0	0	1	1	0
8227	63	2	1	1	5	402	1478	24	22	1926	0	1	0	0	1	0
8228	285	4	4	4	17	3100	15000	973	191	19260	0	0	0	1	0	1
8229	70	3	3	0	8	980	6000	332	78	7390	0	0	1	0	1	0
8230	120	2	2	2	8	1585	12000	279	155	14020	0	0	1	0	0	0

8231 rows × 16 columns

Разделение данных на обучающую и тестовую выборки

Выделим из датасета целевой признак и параметры, также исключим из датасета те столбцы, которые сильно коррелируют между собой

In [17]:
```
features = data_ohe.drop(['total', 'rent_amount', 'bathroom'], axis=1)
target = data_ohe['total']
```

In [18]:
```
features_train, features_test, target_train, target_test = train_test_split(features,
                                                                            target,
                                                                            test_size=0.25,
                                                                            random_state=1)
```

In [19]:
```
print(features_train.shape, features_test.shape)
```

```
(6173, 13) (2058, 13)
```

In [20]:
```
print(target_train.shape, target_test.shape)
```

```
(6173,) (2058,)
```

Обучение моделей

Обучение модели решающего дерева

In [21]:
```
model_DT = DecisionTreeRegressor(random_state=1, max_depth=10)
```

In [22]:
```
%%time
model_DT.fit(features_train, target_train)
```

```
Wall time: 19 ms
```

Out[22]:
```
DecisionTreeRegressor(max_depth=10, random_state=1)
```

In [23]:
```
predictions_DT = model_DT.predict(features_test)
```

In [24]:
```
print('Decision Tree:', mean_absolute_error(target_test, predictions_DT))
```

```
Decision Tree: 332.5153566973952
```

Обучение модели градиентного бустинга

In [25]:
```
model = XGBRegressor(objective='reg:squarederror')
```

In [26]:
```
cv = RepeatedKFold(n_splits=10, n_repeats=3, random_state=1)
n_scores = cross_val_score(model, features, target, scoring='neg_mean_absolute_error', cv=cv, n_jobs=-1, error_score='raise')
```

In [27]:
```
print('MAE (Средняя Абсолютная Ошибка): %.3f (%.3f)' % (np.mean(n_scores), np.std(n_scores)))
```

```
MAE (Средняя Абсолютная Ошибка): -181.386 (126.665)
```

In [28]:
```
model = XGBRegressor(objective='reg:squarederror')
```

In [29]:
```
%%time
model.fit(features_train, target_train)
```

```
Wall time: 194 ms
```

Out[29]:
```
XGBRegressor(base_score=0.5, booster='gbtree', callbacks=None,
             colsample_bylevel=1, colsample_bynode=1, colsample_bytree=1,
             early_stopping_rounds=None, enable_categorical=False,
             eval_metric=None, gamma=0, gpu_id=-1, grow_policy='depthwise',
             importance_type=None, interaction_constraints='',
             learning_rate=0.300000012, max_bin=256, max_cat_to_onehot=4,
             max_delta_step=0, max_depth=6, max_leaves=0, min_child_weight=1,
             missing=nan, monotone_constraints='()', n_estimators=100, n_jobs=0,
             num_parallel_tree=1, predictor='auto', random_state=0, reg_alpha=0,
             reg_lambda=1, ...)
```

In [30]:
```
predictions_GB = model.predict(features_test)
```

In [31]:
```
print('Gradient boosting:', mean_absolute_error(target_test, predictions_GB))
```

```
Gradient boosting: 137.5728101368896
```

Подбор гиперпараметров

Гиперпараметры модели дерева решений

In [32]:
```
n_range = np.array(range(1, 41, 2))
tuned_parametrs = [{'max_depth' : n_range}]
tuned_parametrs
```

Out[32]:
```
[{'max_depth': array([ 1,  3,  5,  7,  9, 11, 13, 15, 17, 19, 21, 23, 25, 27, 29, 31, 33,
         35, 37, 39])}]
```

In [33]:
```
%%time

tuned_DT = GridSearchCV(DecisionTreeRegressor(random_state=1), tuned_parametrs, cv=5, scoring='neg_mean_absolute_error')
tuned_DT.fit(features, target)
```

```
Wall time: 3.07 s
```

Out[33]:
```
GridSearchCV(cv=5, estimator=DecisionTreeRegressor(random_state=1),
             param_grid=[{'max_depth': array([ 1,  3,  5,  7,  9, 11, 13, 15, 17, 19, 21, 23, 25, 27, 29, 31, 33,
       35, 37, 39])}],
             scoring='neg_mean_absolute_error')
```

In [34]:
```
tuned_DT.best_params_
```

Out[34]:
```
{'max_depth': 27}
```

Гиперпараметры модели градиентного бустинга

In [35]:
```
param_test = {
'gamma':[0, 0.3, 0.4, 0.5],
'subsample':[0, 0.3, 0.5, 0.7, 0.9],
'reg_lambda':[1,5,10],
'max_depth':[1, 3, 5],
'colsample_bytree' : [0.2, 0.4, 0.8, 1]}
```

In [36]:
```
%%time

tuned_GB = GridSearchCV(XGBRegressor(objective='reg:squarederror'), param_grid = param_test, scoring='neg_mean_squared_error', cv=5 )
tuned_GB.fit(features, target)
```

```
Wall time: 6min 42s
```

Out[36]:
```
GridSearchCV(cv=5,
             estimator=XGBRegressor(base_score=None, booster=None,
                                    callbacks=None, colsample_bylevel=None,
                                    colsample_bynode=None,
                                    colsample_bytree=None,
                                    early_stopping_rounds=None,
                                    enable_categorical=False, eval_metric=None,
                                    gamma=None, gpu_id=None, grow_policy=None,
                                    importance_type=None,
                                    interaction_constraints=None,
                                    learning_rate=None, max_bin=None,
                                    max_cat...
                                    min_child_weight=None, missing=nan,
                                    monotone_constraints=None, n_estimators=100,
                                    n_jobs=None, num_parallel_tree=None,
                                    predictor=None, random_state=None,
                                    reg_alpha=None, reg_lambda=None, ...),
             param_grid={'colsample_bytree': [0.2, 0.4, 0.8, 1],
                         'gamma': [0, 0.3, 0.4, 0.5], 'max_depth': [1, 3, 5],
                         'reg_lambda': [1, 5, 10],
                         'subsample': [0, 0.3, 0.5, 0.7, 0.9]},
             scoring='neg_mean_squared_error')
```

In [37]:
```
tuned_GB.best_params_
```

Out[37]:
```
{'colsample_bytree': 1,
 'gamma': 0,
 'max_depth': 3,
 'reg_lambda': 1,
 'subsample': 0.5}
```

Обучение оптимальных моделей

Дерево решений

In [38]:
```
tuned_DT.best_estimator_.fit(features_train, target_train)
```

Out[38]:
```
DecisionTreeRegressor(max_depth=27, random_state=1)
```

In [39]:
```
predictions_DT_tuned_train = tuned_DT.best_estimator_.predict(features_train)
predictions_DT_tuned_test = tuned_DT.best_estimator_.predict(features_test)
```

Градиентный бустинг

In [40]:
```
tuned_GB.best_estimator_.fit(features_train, target_train)
```

Out[40]:
```
XGBRegressor(base_score=0.5, booster='gbtree', callbacks=None,
             colsample_bylevel=1, colsample_bynode=1, colsample_bytree=1,
             early_stopping_rounds=None, enable_categorical=False,
             eval_metric=None, gamma=0, gpu_id=-1, grow_policy='depthwise',
             importance_type=None, interaction_constraints='',
             learning_rate=0.300000012, max_bin=256, max_cat_to_onehot=4,
             max_delta_step=0, max_depth=3, max_leaves=0, min_child_weight=1,
             missing=nan, monotone_constraints='()', n_estimators=100, n_jobs=0,
             num_parallel_tree=1, predictor='auto', random_state=0, reg_alpha=0,
             reg_lambda=1, ...)
```

In [41]:
```
predictions_GB_tuned_train = tuned_GB.best_estimator_.predict(features_train)
predictions_GB_tuned_test = tuned_GB.best_estimator_.predict(features_test)
```

Оценка качества полученных моделей

Для оценки качестве полученных моделей использовались стандартные метрики качества для задачи регрессии: MAE, MSE, RMSE, R2.

In [42]:
```
mae_dict = {}
mse_dict = {}
rmse_dict = {}
r2_dict = {}
```

In [43]:
```
mae_dict = {'Gradient boosting' : mean_absolute_error(target_test, predictions_GB_tuned_test),
            'Decision Tree' : mean_absolute_error(target_test, predictions_DT_tuned_test)}
mae_dict
```

Out[43]:
```
{'Gradient boosting': 184.96150440330987, 'Decision Tree': 225.78668610301264}
```

In [44]:
```
mse_dict = {'Gradient boosting' :  mean_squared_error(target_test, predictions_GB_tuned_test),
            'Decision Tree' : mean_squared_error(target_test, predictions_DT_tuned_test)}
mse_dict
```

Out[44]:
```
{'Gradient boosting': 252668.6721635518, 'Decision Tree': 379375.7653061224}
```

In [45]:
```
rmse_dict = {'Gradient boosting' : mean_squared_error(target_test, predictions_GB_tuned_test, squared=False),
             'Decision Tree' : mean_squared_error(target_test, predictions_DT_tuned_test, squared=False)}
rmse_dict
```

Out[45]:
```
{'Gradient boosting': 502.6615881122724, 'Decision Tree': 615.9348709937784}
```

In [46]:
```
r2_dict = {'Gradient boosting' : r2_score(target_test, predictions_GB_tuned_test),
           'Decision Tree' : r2_score(target_test, predictions_DT_tuned_test)}
r2_dict
```

Out[46]:
```
{'Gradient boosting': 0.9996095922331323, 'Decision Tree': 0.999413812388894}
```

In [47]:
```
plt.bar(mae_dict.keys(), mae_dict.values(), color='g')
```

Out[47]: <BarContainer object of 2 artists>

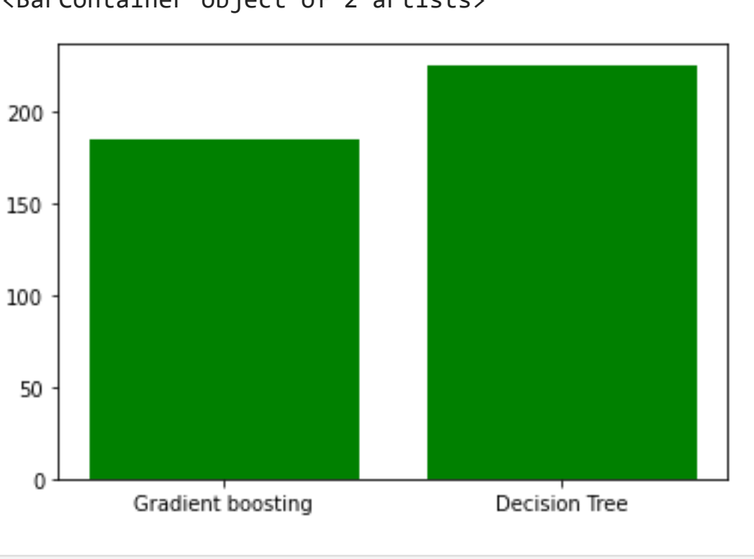

In [48]:
```
plt.bar(mse_dict.keys(), mse_dict.values(), color='g')
```

Out[48]: <BarContainer object of 2 artists>

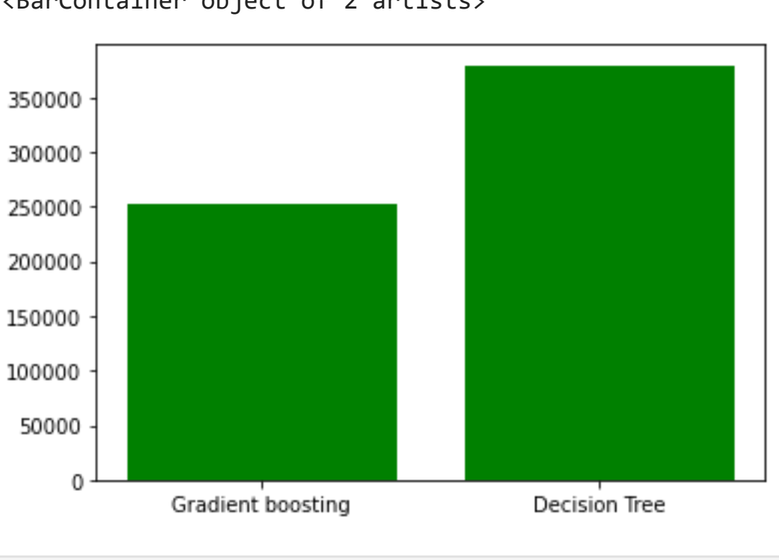

In [49]:
```
plt.bar(rmse_dict.keys(), rmse_dict.values(), color='g')
```

Out[49]: <BarContainer object of 2 artists>

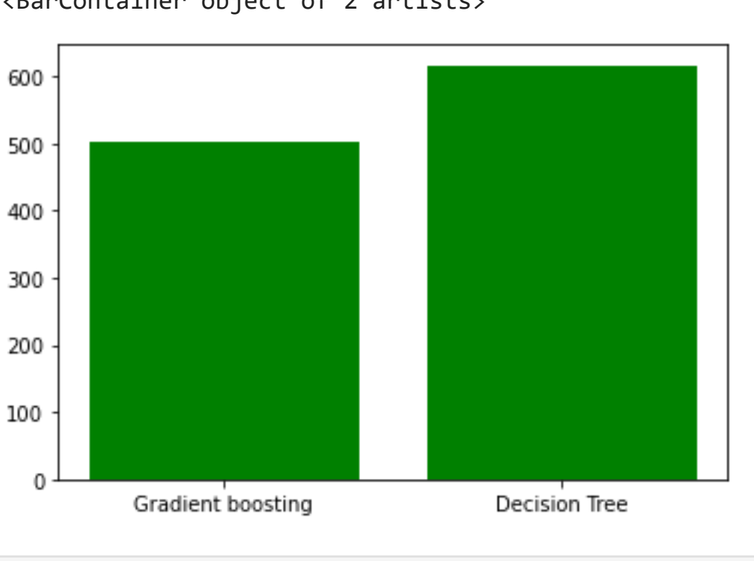

In [50]:
```
plt.bar(r2_dict.keys(), r2_dict.values(), color='g')
```

Out[50]: <BarContainer object of 2 artists>

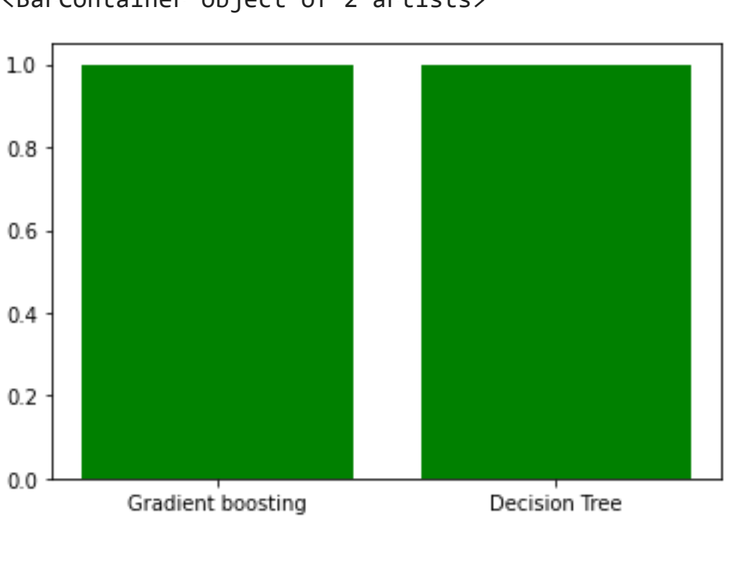

Выводы

Обе полученные модели обладают достаточно неплохим качеством, что хорошо видно на значениях метрик, в плане точности предсказаний лучше себя проявила модель Градиентного бустинга, однако в скорости обучения гораздо сильнее, что логично, выиграла модель Решающего дерева, при это частично проиграв в качестве предсказаний.